

| Guía de Estudio Ingeniería | | | |
|---|--|---|--|
| TEMA 1. INTRODUCCIÓN A LAS TECNOLOGÍAS BIG DATA | 1.1. Las Tres V's del Big Data | **Volumen, Velocidad y Variedad** son las características principales del Big Data. Entenderlas es clave para identificar un proyecto de Big Data. | |
| | | **Volumen**: Se refiere a la gran cantidad de datos que se generan y necesitan ser procesados. | |
| | | **Velocidad**: La rapidez con la que se generan y procesan los datos. | |
| | | **Variedad**: La diversidad de los tipos de datos, estructurados y no estructurados. | |
| | 1.2. Definición de Big Data y sus Aplicaciones | Big Data son conjuntos de tecnologías diseñadas para manejar grandes volúmenes de datos heterogéneos. | |
| | | **Apache Kafka**: Es un sistema de mensajería que permite manejar flujos de datos en tiempo real. | |
| TEMA 2. HDFS Y MAPREDUCE | 2.1. HDFS (Hadoop Distributed File System) | HDFS es un sistema de archivos distribuido que permite el almacenamiento y procesamiento de grandes volúmenes de datos a través de múltiples máquinas. | |
| | | Comandos HDFS relevantes: | **mkdir**: Crea un nuevo directorio en HDFS. |
| | | | **rm**: Elimina archivos en HDFS, y puede hacerlo de manera recursiva para carpetas. |
| | | | **chmod**: Cambia los permisos de un archivo en HDFS. |
| | 2.2. MapReduce y Apache Spark | <p>**MapReduce**: Es un paradigma de programación para procesar datos distribuidos en clústeres. Se basa en las funciones Map y Reduce.</p> <p>**Apache Spark**: Mejora las limitaciones de MapReduce al permitir operaciones en memoria y un procesamiento más rápido.</p> <p>**Funciones Map y Reduce**: Spark permite realizar operaciones de mapeo y reducción en paralelo, distribuyendo tareas entre nodos.</p> | |
| TEMA 3. SPARK I | 3.1. Aprendizaje Automático en Big Data | Los algoritmos de Machine Learning se benefician de Spark al permitir múltiples iteraciones sobre los datos. | |
| | | **RDD (Resilient Distributed Dataset)**: Es una estructura de datos clave en Spark que permite almacenar y procesar datos en paralelo. | |
| | 3.2. Métodos Principales en Spark ML | El método "fit" es el principal en los estimadores de Spark ML para ajustar los modelos a los datos. | |
| | | **Transformers** y **Pipelines**: Después del entrenamiento, los modelos utilizan estas interfaces para procesar nuevos datos. | |
| TEMA 4. SPARK II | 4.1. DataFrames y SQL en Spark | **DataFrames**: Estructuras de datos distribuidas que permiten manipular datos de forma eficiente en Spark. | |
| | | **Spark SQL**: Interfaz que permite ejecutar consultas SQL sobre DataFrames. | |
| TEMA 5. SPARK III | 5.1. Spark MLlib y Structured Streaming | **MLlib**: Biblioteca de aprendizaje automático de Spark que incluye algoritmos como regresión, clasificación y clustering. | |
| | | **Spark Structured Streaming**: Módulo para procesar flujos de datos en tiempo real. | |
| TEMA 6. APACHE KAFKA | 6.1. Introducción a Apache Kafka | Kafka es una plataforma de mensajería distribuida que permite la publicación, suscripción y procesamiento de flujos de datos en tiempo real. | |
| | | **Producers y Consumers**: Los productores envían mensajes a Kafka, mientras que los consumidores los leen para su procesamiento. | |
| TEMA 7. HIVE E IMPALA | 7.1. Apache Hive y Apache Impala | **Hive**: Herramienta para manejar datos en HDFS usando SQL. | |
| | | **Impala**: Motor de consultas SQL que permite ejecutar consultas en HDFS con alta eficiencia. | |
| TEMA 8. CLOUD COMPUTING I | 8.1. Introducción a Cloud Computing | **Cloud Computing**: Modelo de computación que permite el acceso a recursos de computación y almacenamiento a través de la nube. | |
| | | **Ventajas del Cloud Computing**: Escalabilidad, reducción de costos y flexibilidad en el acceso a los recursos. | |
| | 8.2. Servicios en la Nube | **Tipos de Nube**: Pública, privada, híbrida. | |
| | | **Servicios en la Nube**: IaaS, PaaS, SaaS. | |
| | | **Microsoft Azure**: Plataforma en la nube que ofrece una amplia gama de servicios. | |
| TEMA 9. CLOUD COMPUTING II | 9.1. Amazon Web Services (AWS) | **AWS**: Plataforma de servicios en la nube que ofrece soluciones de computación, almacenamiento, bases de datos y más. | |
| | | **Servicios de AWS**: Computación, almacenamiento, redes, bases de datos, seguridad y más. | |
| TEMA 10. CLOUD COMPUTING III | 10.1. Google Cloud Platform (GCP) | **GCP**: Plataforma de servicios en la nube de Google que ofrece soluciones de computación, almacenamiento, bases de datos, y análisis de Big Data. | |
| | | **Servicios de GCP**: Computación, almacenamiento, redes, bases de datos, y machine learning. | |