



# Análisis e Interpretación de Datos

Dra. Mariana Edith Miranda Varela

7 julio 2025

# Regresión lineal simple

## Dataset

Seguro de automóviles en Suecia

X = número de accidentes


Y = pago total de todos los accidentes en miles de coronas suecas en Suecia

Referencias:

<https://data.world/anujonthemove/auto-insurance-in-sweden>


[https://college.cengage.com/mathematics/brase/understandable\\_statistics/7e/students/datasets/slr/frames/slr06.html](https://college.cengage.com/mathematics/brase/understandable_statistics/7e/students/datasets/slr/frames/slr06.html)

## Gráfico de dispersión



Coeficiente de relación  
**0.91287824**

## Recta de mínimos cuadrados



$$\hat{y} = a + bx$$
$$b = r \frac{s_x}{s_y}$$
$$a = \bar{y} - b\bar{x}$$

Fuente: <http://blog.espol.edu.ec/analisisnumerico/minimos-cuadrados-con-python/>

## Homocedasticidad

$$E(e_i^2) = \sigma_i^2$$

El término de error tiene la misma varianza en cada observación

### Supuesto de homocedasticidad

Los residuos se distribuyen de manera homogénea para todos los valores de la variable predicha

### Ausencia de homocedasticidad

- Omisión de variables importantes en el modelo

## Comando lm

$$\hat{y} = 19.9945 + 3.4138x$$

Coeficiente de determinación mide la bondad del ajuste de la recta a los datos

Variable dependiente      Variable independiente

```
> reg_S <- lm(Y ~ X, data = df_Suecia)
> summary(reg_S)
```

Call:  
lm(formula = Y ~ X, data = df\_Suecia)

Residuals:

Min	1Q	Median	3Q	Max
-86.561	-24.051	-0.347	23.432	83.977

Coefficients:

	Estimate	Std. Error	t value	P-value
(Intercept)	19.9945	6.3678	3.14	0.0026 **
X	3.4138	0.1955	17.46	<2e-16 ***

---

Signif. codes: 0 '\*\*\*\*' 0.001 '\*\*\*' 0.01 '\*\*' 0.05 '\*' 0.1 '.' 1



Residual standard error: 35.94 on 61 degrees of freedom  
Multiple R-squared: 0.8333, Adjusted R-squared: 0.8306  
F-statistic: 305 on 1 and 61 DF, p-value: < 2.2e-16

P-values para los coeficientes

# Regresión lineal múltiple

# Enfermedades del corazón

- Variables independientes
  - biking → **-0.935455474**
  - smoking → **0.309130979**
- Variable dependiente
  - heart.disease



## Otros tipos de regresión

- **Modelo lineal generalizado**
  - Gráfico de dispersión no muestra una relación lineal
  - Transformar variables
  - Función `glm`
- **Regresión de mínimos cuadrados recortados**
  - Se emplea en datos que tienen outliers
  - Función `ItsReg`

# Gráficos de residuos


## Gráfico de residuos

Permiten evaluar lo siguiente:


- Si el modelo debe ser no lineal en un lugar uno lineal
- Si la varianza es constante, esto es, los residuos se distribuyen al azar alrededor del cero.
- Si existen datos atípicos (outliers)

## Homocedasticidad vs heterocedasticidad

Ejemplo de Homocedasticidad



Ejemplo de heterocedasticidad




$$\hat{y}_i = a + bx$$

donde  $b x_i = 0$

FUENTE: <https://ecab-estadistica.medium.com/homocedasticidad-vs-heterocedasticidad-34b36cefaf9#:~:text=En%20concreto%2C%20un%20modelo%20lineal,contrario%2C%20el%20modelo%20ser%C3%A1%20heteroced%C3%A1stico.>

## Desbalance en el eje Y




### SOLUCIÓN

- Transformar los datos, específicamente la variable dependiente (de respuesta)
- Existe la posibilidad de que al modelo le falte una variable

FUENTE: <https://www.qualtrics.com/support/stats-iq/analyses/regression-guides/interpreting-residual-plots-improve-regression/>

# Heterocedasticidad





La heterocedasticidad se presenta cuando los residuos aumentan a medida que la predicción cambia de pequeña a grande, forma de embudo o abanico.

## SOLUCIÓN

- Transformar una variable
- La heterocedasticidad indica que al modelo le falta una variable

FUENTE: <https://www.qualtrics.com/support/stats-iq/analyses/regression-guides/interpreting-residual-plots-improve-regression/>

# No lineal





Los residuos tienen un patrón curvilíneo

## SOLUCIÓN

- Transformar una variable
- Modelo de regresión no lineal
- Existe la posibilidad de que al modelo le falte una variable

FUENTE: <https://www.qualtrics.com/support/stats-iq/analyses/regression-guides/interpreting-residual-plots-improve-regression/>

# Outliers





Un punto lejos del cero

## SOLUCIÓN

- Borrar los datos outliers.
- Transformar la variable que tenga distribución asimétrica
- Evaluar el impacto del dato atípico en caso de que este correcto

FUENTE: <https://www.qualtrics.com/support/stats-iq/analyses/regression-guides/interpreting-residual-plots-improve-regression/>

## Desbalance en el eje X



### SOLUCIÓN

- Transformar los datos, normalmente una variable independiente (explicativa)
- Existe la posibilidad de que al modelo le falte una variable

FUENTE: <https://www.qualtrics.com/support/stats-iq/analyses/regression-guides/interpreting-residual-plots-improve-regression/>

## | Próxima sesión

Semana 7  
21 al 25 de julio

muchas gracias.