


Trabajo Final de Maestría

Modelado de datos

Índice

Esquema	3
Ideas clave	4
4.1. Introducción y objetivos	4
4.2. Identificación de técnicas de modelado	5
4.3. Configuración y parametrización	9
4.4. Recurrencia en el análisis del dato	10
4.5. Reutilización de modelos	12
4.6. Referencias bibliográficas	15
A fondo	16



4.1. Introducción y objetivos

Después del arduo trabajo de comprensión y preparación de los datos, el paso siguiente es delegar a las herramientas analíticas los *dataset* para que estos puedan arrojar alguna guía o luz al problema de negocio planteado.

En este tema el estudiante comprenderá que lo que se conoce como modelado de datos realmente es una **ejecución de múltiples iteraciones** en donde los analistas de datos ejecutan varios modelos utilizando los parámetros predeterminados y ajustan los parámetros o vuelven a la fase de preparación de datos para las manipulaciones necesarias por su modelo.

En proyectos de análisis de datos, el modelado de datos se refiere a la creación de un modelo que describe **cómo se relacionan** los datos y **cómo se pueden utilizar** para lograr los objetivos de análisis. Este modelo puede incluir diferentes componentes, como (Riquelme Santos, Ruiz y Gilbert, 2006):

- ▶ La definición de variables.
- ▶ La identificación de las relaciones entre variables.
- ▶ La selección de algoritmos de análisis.
- ▶ La construcción de modelos predictivos.

El modelado de datos en proyectos de análisis de datos puede involucrar técnicas estadísticas, de minería de datos, aprendizaje automático y otras herramientas de análisis para **identificar patrones y relaciones** en los datos. Esto puede incluir la exploración de los datos, la limpieza de estos y la selección de los mejores algoritmos y modelos para la tarea de análisis específica.

Los objetivos principales de esa fase de tu trabajo final de maestría (TFM) son siguientes:

- ▶ Definir las variables **más idóneas** para el modelado de datos.
- ▶ Identificar las **relaciones** entre las variables seleccionadas como idóneas para comprender su dependencia y utilidad.
- ▶ **Seleccionar** los algoritmos de análisis y la construcción de modelos predictivos que sirvan para abordar el problema planteado en el TFM.

Ten presente que un proyecto de análisis de datos no siempre debe concluir en la construcción de un modelo de aprendizaje automático. En ocasiones, con un simple **modelo descriptivo** es posible abordar un problema planteado y brindar así solución desde el punto de vista descriptivo.

La elección del aprendizaje automático como parte de tu proyecto dependerá de tu trabajo en el tema anterior y de la necesidad de aprender de los datos para **predecir** algún tipo de salida o su comportamiento.

4.2. Identificación de técnicas de modelado

La selección de modelo es una parte importante del proceso de modelado de datos en los proyectos de análisis de datos. El objetivo de esta selección es **identificar** el que **mejor** se ajusta a los datos y el que podría proporcionar resultados **precisos y confiables**.




Figura 1. Esquema CRISP-DM. Fase de Modelado. Fuente: IBM, s. f.

La metodología CRISP-DM nos propone el modelado como una fase importante que todo proyecto de datos debe describir y trabajar de la forma más ordenada posible.

Algunas **técnicas** comunes de selección de modelo utilizadas en análisis de datos son las siguientes:

- ▶ **Validación cruzada:** esta técnica implica **dividir** los datos en conjuntos de entrenamiento y prueba y probar varios modelos con diferentes configuraciones para determinar cuál proporciona los mejores resultados. La validación cruzada es útil para evitar el **sobreajuste** del modelo.

- ▶ **AIC y BIC:** el criterio de información de Akaike (AIC) y el criterio de información bayesiano (BIC) son métodos que proporcionan una forma objetiva de **comparar** modelos y seleccionar el mejor. Ambos criterios tienen en cuenta tanto la **calidad** del ajuste del modelo como la **complejidad** del modelo.

- ▶ **Regularización:** esta es una técnica utilizada para **reducir el sobreajuste** en modelos de aprendizaje automático. Los métodos de regularización, como la

regresión ridge y la regresión Lasso, **penalizan** los coeficientes de las variables menos importantes, evitando así el sobreajuste.

- ▶ **Pruebas de hipótesis:** se habló de hipótesis en el tema anterior y una asignatura del máster, y en ambas se decía que las pruebas de hipótesis pueden utilizarse para comparar diferentes modelos y determinar si existe una **diferencia significativa** entre ellos. Por ejemplo, la prueba H se utiliza para comparar la varianza explicada por diferentes modelos.
- ▶ **Análisis de sensibilidad:** este análisis se utiliza para evaluar **cómo varían** los resultados del modelo cuando se cambian las suposiciones o los parámetros. El análisis de sensibilidad puede ayudar a identificar las variables **críticas** y a evaluar la robustez del modelo.

La elección de la técnica de selección de modelo adecuada depende del tipo de modelo, los datos disponibles y los objetivos del análisis.

Consideraciones para la elección del modelo

La elección del modelado más adecuado para el proyecto se basará en las siguientes consideraciones:

- ▶ Los **tipos de datos disponibles**. Una pregunta útil en este caso es ¿los campos de interés son categóricos o simbólicos?
- ▶ Los **objetivos** del análisis de datos. Determina si lo que se quiere es tener un mejor conocimiento de los datos transaccionales y descubrir patrones de compras interesantes. También es importante establecer si lo que se quiere es generar un valor concreto que represente, por ejemplo, la probabilidad de impago de un préstamo a un cliente.

- ▶ **Requisitos específicos** de modelado. Es importante que también pienses en el modelo previamente en función de los datos que dispone. El modelo para elegir debe considerar el **tipo o tamaño** de la consolidación de datos. También debe tener en cuenta si lo que se quiere son resultados fácilmente presentables o explicables.

Tareas previas para la selección del modelo

Cuando el paso siguiente sea decidir el modelo a utilizar, debes tener en cuenta los siguientes aspectos que pueden afectar a tus alternativas:

- ▶ Necesita el modelo que los datos se dividan en conjuntos de entrenamiento y prueba: Sí/No.
- ▶ Cuenta con los datos suficientes para generar resultados fiables para un modelo concreto: Sí/No.
- ▶ El modelo necesita un cierto nivel de calidad de datos y es posible alcanzar este nivel con los datos disponibles: Sí/No.
- ▶ Los datos son del tipo correcto para un modelo concreto. Si de primeras esto no se cumple, es posible realizar las conversiones necesarias utilizando transformaciones sobre los datos: Sí/No.

Si a todo respondiste que sí, entonces el futuro de esta tarea se limita solo a la elección de la técnica que **mejor se ajuste** al problema. Conforme avances el problema, registra el proceso de toma de decisiones para evitar que otros desconozcan los factores que han afectado a estas decisiones. No olvides documentar cualquier supuesto de datos y modificación realizada para cumplir los requisitos del modelo.

Otros ajustes previos

Procura definir **cómo comprobarás** los resultados de tu modelo. Existen dos partes para generar un diseño de comprobación **global**:

- ▶ Descripción de los criterios de **bondad** de un modelo.
- ▶ Definición de los datos en los que se comprobarán estos criterios.

Cuando se habla de bondad del modelo se hace referencia a varias medidas que dependen del propio modelo. Por ejemplo, para modelos supervisados como C5.0 y C&R Tree, las mediciones de bondad suelen calcular la tasa de error de un modelo concreto. Para modelos sin supervisión, como redes de clústeres de Kohonen, las mediciones pueden incluir criterios como facilidad de interpretación, despliegue o el tiempo de procesamiento necesario (IBM, s. f.).

Generar un modelo es una tarea iterativa y eso significa que, normalmente, se comprueban los resultados de varios modelos antes de decidir los que se usarán y los que se desplegarán.

4.3. Configuración y parametrización

La tarea de generar los modelos ya no debe ser un problema en tu proyecto una vez tienes la posibilidad de elegir las técnicas. Como analista debes tener la capacidad para ejecutar los modelos que hayas considerado.

Es importante que dediques tiempo suficiente a esta fase porque será necesario **experimentar** con diferentes modelos antes de llegar a conclusiones definitivas. Es muy común que se generen varios modelos y se compararen sus resultados para **justificar** la elección y decidir desplegarlos o integrarlos a un entorno real o productivo.




Figura 2. Ejemplo de especificaciones para la elección de modelos propuesta por Scikit Learn. Fuente: scikit learn, s. f.

Dado que la tarea de ejecución de modelos es un proceso iterativo, es importante que **documentes y registres** todos los progresos. Es necesario guardar los ajustes y los datos utilizados para cada modelo y así **evitar perder información** de valor que permitiría rehacer el proceso de forma rápida. Lo que se busca con esta medida es que sea posible analizar los resultados con otras personas y se puedan comprobar sus pasos, si fuera necesario.

Después de elegir el modelo o los modelos, podrás disponer de tres tipos de información que pueden utilizarse en el análisis, estos son:

- ▶ **Configuración de parámetros** incluyendo las observaciones que se han registrado sobre los parámetros que producen los mejores resultados.
- ▶ Los **modelos reales producidos**.
- ▶ **Descripciones de resultados** de modelos teniendo en cuenta los problemas de datos y de rendimiento que hayan ocurrido durante la ejecución de este.

4.4. Recurrencia en el análisis del dato

La **recurrencia** también se conoce como retroalimentación o realimentación, y en el ámbito del análisis de datos se refiere a la capacidad de un modelo para utilizar sus **propias predicciones anteriores** como entradas para las predicciones nuevas o actuales.

Dicho de otro modo, la recurrencia permite que la salida de un modelo se retroalimente en el modelo para influir en sus predicciones futuras.

La recurrencia es muy útil en situaciones en las que los datos **cambian** con el tiempo o en los que la secuencia de los datos es importante. Al utilizar la retroalimentación, el modelo puede **aprender** de sus propias predicciones anteriores y **ajustar** sus predicciones futuras en consecuencia. Esto puede ayudar a **mejorar la precisión** de las predicciones y hacer que el modelo sea más adaptable a los cambios en los datos (Norman, 2019).

Algunos modelos que utilizan la recurrencia en sus procesos de aprendizaje y ajustes son las **redes neuronales recurrentes** (RNN), una forma de red neuronal que utiliza la retroalimentación para procesar secuencias de datos. Los modelos ARIMA (Autoregressive Integrated Moving Average) son otro ejemplo de modelos que utilizan la retroalimentación para modelar datos de series de tiempo. La recurrencia también se utiliza en el procesamiento del lenguaje natural para analizar y generar texto en secuencias.




Figura 3. Ejemplo de RNR y la forma de aprovechar la salida como elemento de aprendizaje o ajuste. Fuente: Software Técnico Libre, 2016.

Recuerda: tu director de TFM no tiene por qué saber sobre tus datos; tu misión es, justamente, enseñarle la viabilidad del proyecto con los *datasets* que has elegido para trabajar.

4.5. Reutilización de modelos

La reutilización de modelos es una práctica que consiste en utilizar **modelos ya existentes** en lugar de crear nuevos modelos desde cero para tareas de análisis de datos **similares**. Es una práctica que podría ser beneficiosa porque puede **ahorrar tiempo y recursos** al evitar la necesidad de crear nuevos modelos y permitir una mayor eficiencia en el proceso de análisis.

Esta técnica puede enfocarse de diferentes formas. Por ejemplo, se puede utilizar un modelo preentrenado para una tarea similar y **ajustarlo** para que se adapte a los nuevos datos. Otro enfoque es utilizar modelos existentes como **punto de partida** para crear nuevos modelos, modificándolos o combinándolos con otros modelos.




Figura 4. MediaPipe, ejemplo de modelos pre-entrenados en el ámbito de Computer Vision.

Fuente: MediaPipe.

Tanto si el objetivo es ahorrar tiempo como recursos, poder reutilizar modelos es algo que podría mejorar la **calidad** y la **precisión** de los resultados del análisis de datos. La razón de ello es que los modelos preexistentes pueden estar diseñados para manejar una amplia variedad de datos, incluyendo datos más complejos y con mayor variabilidad, mejorando así la capacidad de adaptación de dicho modelo a nuevos datos.

Es importante tener presente que no todos los modelos son **adecuados** para todas las tareas de análisis de datos. Los modelos preexistentes deben ser **valorados detalladamente** para comprobar si son **apropiados** para la tarea en cuestión y si necesitan ser **ajustados o mejorados**. En muchos casos será necesario crear un nuevo modelo concreto para los datos y la tarea del problema de tu propuesta de trabajo final.

Algunos **problemas** habituales de la reutilización de modelos preexistentes son los siguientes:

- ▶ **Incompatibilidad de los datos:** no sería extraño que un modelo preentrenado sea incompatible con los datos nuevos o necesite de modificaciones para adaptarse a ellos. Esto puede deberse a diferencias en la estructura de los datos, en su calidad, en su distribución, entre otros muchos factores.
- ▶ **Overfitting o underfitting:** los dos grandes problemas del uso de modelos preentrenados que se deben a que pueden ser, o muy complejos, o demasiado simple para los nuevos datos. En ambos casos es posible encontrarse con *overfitting* o *underfitting*.
- ▶ **Sesgo del modelo:** es otro problema habitual de los modelos preentrenados en nuestra solución, lo cual se debe, posiblemente, a su **poca capacidad** para adaptarse a los nuevos datos o a no ser capaz de producir resultados precisos y justos.
- ▶ **Dificultad para interpretar los resultados:** si la **complejidad** es una característica del modelo preentrenado, será difícil interpretar los resultados y explicar con claridad las características del comportamiento de dicho modelo. Es decir, no habrá forma sencilla de entender y presentar cómo se están llevando a cabo las predicciones.

Es importante **evaluar y comprobar** cuidadosamente los modelos preexistentes antes de utilizarlos en el análisis de datos. Esto puede implicar realizar pruebas en los datos de entrenamiento y los datos de prueba para evaluar la **precisión y la adecuación** del modelo para los nuevos datos, así como realizar ajustes o mejoras si es necesario.

No se deben pasar por alto los posibles problemas de sesgos en los datos y en el propio modelo; como analista debes asegurarte de que el modelo genere resultados **justos y precisos**.

4.6. Referencias bibliográficas

IBM. (s. f.). *Conceptos básicos de ayuda de CRISP-DM*. Recuperado el 18 de febrero de 2023 de <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview>

Norman, A. T. (2019). *Aprendizaje automático en acción*. Litres.

Riquelme Santos, J. C., Ruiz, R. y Gilbert, K. (2006). Minería de datos: Conceptos y tendencias. *Inteligencia Artificial: Revista Iberoamericana de Inteligencia Artificial*, 10 (29), 11-18.

Las fases de los procesos de analítica de datos

Podcast Industria 4.0. (2021). *Las fases de los procesos de analítica de datos (big data/smart data)* [Vídeo]. YouTube. <https://www.youtube.com/watch?v=D04v5N1x9Cs>

La analítica de datos en el entorno industrial permite recopilar información de los procesos de fabricación orientada a la mejora de dichos procesos. También se identifica con términos como *big data*, *small data* o *smart data*.

Conceptos básicos de ayuda de CRISP-DM

IBM. (s. f.). *Descripción de los datos*. Recuperado el 18 de febrero de 2023 de <https://www.ibm.com/docs/es/spss-modeler/saas?topic=understanding-describing-data>

CRISP-DM, que son las siglas de Cross-Industry Standard Process for Data Mining, es un método probado para orientar sus trabajos de minería de datos. Utiliza este marco de trabajo, bien como una metodología que incluye descripciones de las fases normales de un proyecto, las tareas necesarias en cada fase y una explicación de las relaciones entre las tareas, o como modelo de proceso en el que ofrece un resumen del ciclo vital de minería de datos.

Fundamentos del Análisis de Datos para Toma de Decisiones

Comunicación Numérica. (2021). *Fundamentos del Análisis de Datos para Toma de Decisiones* [Vídeo]. YouTube. <https://www.youtube.com/watch?v=qvZxvMWMvDo>

Aprende sobre los principales pilares del análisis de datos, su impacto en las decisiones que tomas día a día y las mejores prácticas para comunicar información dentro de una organización.